

MeiFactor – Pesquisa de Arquitetura e IA (100% gratuita / free-tier)

Versão: 1.0

Alternativas **gratuitas** (ou com *free tier*) para LLMs, embeddings, parsing/OCR, RAG, geração de PDFs,

MCP e orquestração no n8n. Prioriza execução **local** e usa *free tiers* apenas como fallback.

1. Estratégia de IA sem custo

- **Primário local:** **Ollama** (CLI/API local) ou **LM Studio** (GUI, API OpenAI-compatible) na mesma VM do n8n.
- **Fallback:** **Cloudflare Workers AI** (cota gratuita diária) quando precisar publicar endpoints públicos.
- **Vetores:** usar **pgvector** no Postgres/Supabase (sem serviços pagos).

Hardware mínimo sugerido

- CPU moderna + **16 GB RAM** rodam **modelos 3B–8B** quantizados (Q4). SSD reduz latência de load.
 - GPU é desejável, mas não obrigatória.
-

2. LLMs locais (chat/relatórios)

Ferramentas

- **Ollama:** baixa e serve modelos em `http://localhost:11434`, com endpoints p/chat/embeddings.
- **LM Studio:** GUI que expõe **API compatível com OpenAI** (fácil para integrar).

Modelos recomendados (leves)

- **Llama 3.x (8B)** • **Mistral 7B** • **Qwen 2 / 2.5 (7B/14B)** • **Phi-3-mini** — em **4-bit** para CPU.

Boas práticas

- Prompt base enxuto; contexto inserido via **RAG**.
 - Limitar tamanho de contexto; cachear outputs repetitivos (quando útil).
-

3. Embeddings 100% gratuitos

- **Sentence-Transformers** (`all-MiniLM-L6-v2` , **384d**): rápido/robusto em CPU.
- **Nomic Embed Text**: bom em `search_document/search_query(task_type)`.
- **BGE (v1.5) small**: alternativa leve.

Dicas

- Padronize a dimensão (ex.: `vector(384)`) para toda a base.
 - Índices **IVFFLAT** (ou HNSW onde disponível) e `ANALYZE` pós-carga.
 - Pós-processamento com **MMR** para diversidade.
-

4. Parsing e OCR (open-source)

- **Unstructured** → normaliza **PDF/DOCX/HTML** em Markdown/JSON.
- **Tesseract OCR** (ou **PaddleOCR**) para escaneados.
- **pdfplumber** para PDFs digitais; **ocrmypdf** (OCR + PDF pesquisável).
- **camelot/tabula** para tabelas; **layoutparser** para análise de layout.

Pipeline (n8n)

1. Recebe upload (`forms/`) → 2) Detecta digital x escaneado → 3) Unstructured/OCR →
 2. Split em chunks (500-1000 tokens, overlap 10-15%) → 5) Embeddings (MiniLM/BGE/Nomic) → `doc_chunks` (pgvector).
-

5. RAG sem custos (pgvector)

- `doc_chunks(org_id, upload_id, content, embedding)` .
- Similaridade **cosine** (quanto menor `<->` , maior similaridade).
- `top-k` 5-12; **MMR** ajuda a reduzir redundância.

SQL base

```
select content, 1 - (embedding <=> :query_embedding) as score
from doc_chunks
```

```
where org_id = :org_id
order by embedding <-> :query_embedding
limit 8;
```

Prompt base

Você é um assistente contábil. Responda apenas com base no CONTEXTO abaixo. Se não houver contexto suficiente, diga explicitamente.

CONTEXTO

PERGUNTA

6. Geração de PDF (gratuito)

- **ReportLab** (programático) ou **WeasyPrint/wkhtmltopdf/Puppeteer** (HTML→PDF).
 - Templates HTML/CSS facilitam manutenção visual.
 - Salvar no Storage `reports/` com **URL assinada** para download.
-

7. MCP (Model Context Protocol)

- Crie um **MCP Server** mínimo (Node/Python) com tools `account.get_me`, `report.run`, `forms.ingest`.
- O cliente (ex.: Claude Desktop) chama as tools; por baixo, o servidor MCP chama seu **Gateway n8n**.
- Mantém o n8n como **orquestrador** e o MCP como “faixa de integração” padronizada.

Passos rápidos

1. Escolher runtime; 2) Implementar tools; 3) Autenticar com token de serviço; 4) Configurar cliente MCP.
-

8. Custos, limites, governança

- **Local** = custo zero e privacidade.
 - **Free tiers**: monitorar cotas (Cloudflare Workers AI).
 - **LGPD**: consentimento, direito de exclusão e audit trail.
 - **Retenção**: limpeza de uploads brutos após processamento.
-

9. “Como ligar tudo” no n8n (checklist)

- Variáveis: `SUPABASE_URL` , `SUPABASE_SERVICE_ROLE_KEY` , `JWT_SECRET` /`RSA`,
`OLLAMA_URL` / `LMSTUDIO_URL` .
 - Sub-workflow **Embeddings** (`texts[]` → vetores → `doc_chunks`).
 - **Parsing** via `Execute Command` (scripts Unstructured/Tesseract).
 - **RAG**: nó Postgres com a query; contexto → LLM local.
 - **Relatório**: gerar PDF → salvar em `reports/` (Storage) → responder `pdf_url` .
 - **Alertas**: Error Workflow habilitado.
-

10. Roadmap

1. **Gateway + Auth** (JWT 48h, escopos, refresh) + **RLS**.
 2. **Account CRUD** + enriquecimento por CNPJ.
 3. **Forms** → **Parsing** → **Embeddings** → **pgvector**.
 4. **Report** (RAG + PDF, assíncrono/polling).
 5. **Chat** (threads + anexos + RAG).
 6. Observabilidade e replay.
-

11. Fontes e ferramentas (para consulta)

- n8n (Webhook, Switch, Execute Workflow, Error handling)
- Supabase (RLS, Storage, pgvector) • PostgreSQL (RLS) • pgvector
- Ollama, LM Studio (LLMs locais) • Cloudflare Workers AI (free tier)
- Sentence-Transformers (MiniLM) • Nomic Embed • BGE
- Unstructured • Tesseract • PaddleOCR • pdfplumber •
wkhtmltopdf/WeasyPrint/Puppeteer/ReportLab
- MCP (Model Context Protocol) – guias e exemplos